

Introduction au Machine Learning

Durée indicative : 2 heures

Public : informaticiens en transition vers la Data Science

Contexte : applications du Machine Learning dans différents domaines

Objectifs pédagogiques

À l'issue de cette séance, vous serez capables de :

- définir simplement le Machine Learning ;
- distinguer **Intelligence Artificielle**, **Machine Learning** et **Deep Learning** ;
- identifier les principaux éléments d'un problème de Machine Learning ;
- distinguer apprentissage **supervisé**, **non supervisé** et **semi-supervisé** ;
- distinguer **classification**, **régression**, **clustering** et **détection d'anomalies** ;
- identifier des cas d'usage du Machine Learning dans différents domaines ;
- déterminer si une problématique est adaptée au Machine Learning ;
- expliquer pourquoi une solution simple basée sur des règles peut parfois être préférable ;
- comprendre les principes de base d'une démarche rigoureuse avec **scikit-learn**.

1. Qu'est-ce que le Machine Learning ?

Partir d'une question simple

Question aux étudiants :

Comment programmeriez-vous un système capable de détecter automatiquement un spam ?

On peut imaginer deux approches.

Approche classique

On écrit des règles :

```
SI le message contient "gagner de l'argent"  
ET contient beaucoup de liens  
ET provient d'une adresse inconnue  
ALORS spam
```

Puis :

```
SI ...  
ALORS ...
```

Rapidement, le nombre de règles devient énorme.

Approche Machine Learning

On fournit au système :

```
Message → Spam  
Message → Non spam  
Message → Spam  
Message → Non spam  
...
```

Le modèle cherche lui-même des régularités permettant de distinguer les deux catégories.

Au lieu de programmer toutes les règles, on fournit des exemples au système et on lui demande d'apprendre des régularités présentes dans les données.

On arrive ainsi à une première définition intuitive :

Le Machine Learning consiste à construire des modèles capables d'apprendre des régularités à partir de données afin de réaliser une tâche, sans programmer explicitement toutes les règles permettant de réaliser cette tâche.


2. Qu'est-ce que le Machine Learning ?

2.1 Une définition intuitive

Le **Machine Learning**, ou apprentissage automatique, est une branche de l'Intelligence Artificielle qui consiste à construire des modèles capables d'apprendre des régularités à partir de données afin de réaliser une tâche.

Une distinction importante avec la programmation classique est la suivante.


Programmation classique



Nous écrivons les règles.

Machine Learning

Apprentissage



L'algorithme construit un **modèle** à partir des données. #### Inférence (utilisation)



2.2 Le mot « apprendre » ne signifie pas comprendre

Lorsqu'on dit qu'un modèle « apprend », il ne faut pas imaginer qu'il raisonne comme un être humain.

Le modèle cherche essentiellement des **relations statistiques** dans les données.


Par exemple, à partir de données historiques :

```
surface habitable
nombre de chambres
nombre de salles de bains
année de construction
état général du logement
localisation
distance au centre-ville
présence d'un garage
classe énergétique
date de la transaction
prix de vente
```

un modèle peut apprendre une relation permettant d'estimer le prix d'un bien immobilier.

- **Variables explicatives** : surface, chambres, localisation, état, équipements, etc.
- **Variable cible** : prix de vente.

3. Data Science, IA, Machine Learning et Deep Learning



Intelligence Artificielle

L'objectif principal de l'Intelligence Artificielle est de créer des systèmes capables d'imiter le comportement et l'intelligence humains pour résoudre des problèmes complexes ou automatiser des tâches.

Machine Learning

Sous-domaine spécifique de l'Intelligence Artificielle. Plutôt que d'être explicitement programmé pour chaque tâche, il construit des modèles à partir de données pour apprendre, s'adapter et réaliser des prédictions ou des décisions automatiques.

Deep Learning

Sous-domaine du Machine Learning (et donc de l'IA). Il se distingue par l'utilisation de réseaux de neurones profonds (plusieurs couches d'apprentissage) et s'avère particulièrement efficace pour traiter des problèmes hautement complexes, comme la reconnaissance d'images ou le traitement du langage naturel.

Data Science

C'est un sous-ensemble large et transversal qui mêle les concepts de l'Intelligence Artificielle et du Machine Learning aux statistiques classiques. La Data Science utilise des méthodes scientifiques pour extraire du sens, des tendances et des connaissances spécifiques à partir de vastes ensembles de données (Big Data).

4. Anatomie d'un problème de Machine Learning

Prenons un exemple métier.

Une agence immobilière souhaite estimer le prix de maisons à partir de leurs caractéristiques.

Nous pouvons disposer d'un jeu de données comme celui-ci :

mai- son	sur- face_m2	nombre_cham- bres	distance_cen- tre_km	annee_construc- tion	prix_eu- ros
A	85	3	8.5	1975	245000
B	120	4	5.2	2008	365000

mai- son	sur- face_m2	nombre_cham- bres	distance_cen- tre_km	annee_construc- tion	prix_eu- ros
C	160	5	1.8	2018	620000
D	210	6	12.0	1990	410000


Chaque ligne correspond à une **observation**.

Les colonnes décrivant l'observation sont les **variables explicatives**, souvent appelées *features*.

La variable que nous souhaitons prédire est la **cible**, ou *target*.

Features	Target
surface_m2	prix_euros
nombre_chambres	
distance_centre_km	
annee_construction	

On peut représenter le problème ainsi :



5. Les grands types de problèmes

Avant même de choisir un algorithme, il faut identifier **le type de problème**.

5.1 Classification

En classification, la cible correspond à une **catégorie**.

Par exemple, une agence immobilière souhaite déterminer si une maison appartient à la catégorie des biens à prix élevé.

La cible peut être définie à partir du prix de vente historique :

- **prix élevé** : prix supérieur à un seuil défini à l'avance ;
- **prix standard** : prix inférieur ou égal à ce seuil.

Le modèle ne reçoit pas le prix de vente comme variable explicative. Il utilise uniquement les caractéristiques disponibles avant la vente.

Exemples de variables explicatives :

- surface habitable ;
- nombre de chambres ;
- distance au centre-ville ;
- année de construction ;
- état général du logement ;
- présence d'un garage ou d'un jardin ;
- quartier.

Entrées

```
surface_m2
nombre_chambres
distance_centre_km
annee_construction
etat_general
presence_garage
quartier
```

↓

Modèle de classification

↓

Sortie

```
"Prix élevé"
"Prix standard"
```

Il s'agit ici d'une **classification binaire**, car le modèle doit choisir entre deux catégories.

La classification peut également comporter plusieurs catégories. Par exemple :

```
"Prix faible"
"Prix moyen"
"Prix élevé"
```

On parle alors de **classification multiclasse**.

Autres exemples de classification :

- transaction frauduleuse / transaction normale ;
- logement avec ou sans risque d'impayé ;
- document appartenant à une catégorie donnée / autre catégorie ;
- client susceptible d'acheter / client probablement non acheteur.

5.2 Régression

En régression, la cible est une **valeur numérique**.

Par exemple, une agence immobilière peut chercher à estimer le prix de vente d'une maison à partir de caractéristiques connues avant la transaction.

Les variables explicatives peuvent être :

- la surface habitable ;
- le nombre de chambres ;
- la distance au centre-ville ;
- l'année de construction ;
- l'état général du logement ;
- la présence d'un garage ou d'un jardin ;
- le quartier.

Entrées

```
surface_m2
nombre_chambres
distance_centre_km
annee_construction
etat_general
presence_garage
quartier
```

↓

Modèle de régression

↓

Sortie

```
Prix de vente estimé
385 000 euros
```

Le modèle produit donc une estimation numérique, par exemple **385 000 euros**. Contrairement à une classification, il ne choisit pas une catégorie comme « prix élevé » ou « prix standard ».

Autres exemples de régression :

- prévoir le nombre de véhicules sur une portion d'autoroute ;
- estimer le niveau d'émissions d'un site industriel ;
- prévoir la consommation électrique d'un bâtiment ;
- estimer le coût d'un projet ;
- prévoir la quantité de déchets produite.

Classification → catégorie

Régression → nombre

5.3 Clustering

Le clustering est une méthode d'apprentissage **non supervisé** qui cherche à regrouper automatiquement des observations présentant des caractéristiques similaires.

Dans cet exemple, une plateforme de streaming vidéo souhaite identifier différents profils d'utilisateurs parmi ses millions d'abonnés, sans avoir défini de catégories à l'avance (elle ne cherche pas à classer entre “hommes/femmes” ou “jeunes/vieux”, mais à découvrir des comportements).


Elle analyse les variables suivantes pour chaque compte :

- Le nombre d'heures de visionnage en semaine
- Le nombre d'heures de visionnage le week-end
- La durée moyenne des sessions (épisodes de 20 min vs films de 2h)
- Le support principal utilisé (Télévision, Smartphone, Tablette)
- La diversité des genres regardés (Action, Comédie, Documentaire...)

L'âge ou la localisation de l'abonné peuvent être utilisés *après coup* pour analyser les groupes obtenus, mais l'algorithme ne se base que sur le comportement de visionnage pour les créer.

La question posée au modèle est donc :

Existe-t-il des groupes naturels d'utilisateurs partageant des habitudes de consommation similaires ?



Les profils comportementaux n'étaient pas connus à l'avance : ils ont émergé des ressemblances entre les milliards d'heures de visionnage analysées.

Une fois ces groupes découverts, la plateforme peut adapter son service (par exemple : recommander des séries courtes sur mobile au Groupe 2 le lundi matin, et des films primés au Groupe 3 le vendredi soir).

Clustering → découverte de profils ou de segments cachés dans les données, sans étiquettes fournies à l'avance.

5.4 Détection d'anomalies

La détection d'anomalies est une méthode qui cherche à identifier les observations **inhabitu**elles ou aberrantes qui s'écartent drastiquement du comportement normal d'un système. Le texte d'origine mélangeait les termes "transaction" et "température" ; il est beaucoup plus clair de séparer les contextes.

L'exemple le plus parlant est celui de la **fraude bancaire**.

Le système connaît les habitudes d'un client :

- Des achats quotidiens en France.
- Des montants généralement compris entre 5 € et 150 €.
- Des transactions effectuées entre 8h et 22h.


Soudain, une transaction de 2 500 € est tentée à 3h du matin depuis un pays étranger.

Cela peut signaler :

- Une carte volée ou piratée (fraude).
- Une erreur technique du terminal de paiement.
- Un voyage non signalé par le client (événement réel mais exceptionnel).

La question posée au modèle est donc :

Cette nouvelle observation appartient-elle à la distribution normale de mes données ou est-elle suspecte ?



Un autre exemple classique concerne la **maintenance prédictive industrielle** : un capteur sur une machine produit habituellement des vibrations stables et une température de 20 °C.

S'il fournit soudainement une température de 85 °C et des vibrations erratiques, le modèle d'anomalie va lever une alerte avant que la machine ne tombe en panne.


Détection d'anomalies → identification de cas rares et suspects au milieu d'une masse écrasante de données normales.

La détection d'anomalies est avant tout une méthode d'apprentissage non supervisé, car elle est très souvent utilisée précisément lorsqu'on ne dispose d'aucun exemple préalable de panne ou de fraude pour entraîner la machine.

Non supervisé (L'approche standard) : L'algorithme ingère un ensemble de données brutes et non étiquetées. Il modélise seul ce qui constitue la "norme" (la zone où se concentre la majorité des observations) et isole géométriquement ou statistiquement les points aberrants.

6. Apprentissage supervisé

Dans l'apprentissage supervisé, le modèle s'entraîne sur des données historiques contenant déjà la réponse attendue (l'étiquette). Son but est d'apprendre la relation entre les variables d'entrée et cette réponse pour l'appliquer à de nouvelles situations.




Exemple : Prédiction d'anomalies immobilières Nous possédons l'historique de 10 000 inspections de maisons. Pour chacune d'entre elles, un expert a déjà validé si une anomalie était présente.

- **Variables d'entrée** : Température, humidité, prix, âge de la maison.
- **Cible (à prédire)** : Présence d'une anomalie (Oui / Non).

Le modèle étudie ces 10 000 exemples pour apprendre quelles combinaisons de caractéristiques conduisent à une anomalie. Il devient alors capable de diagnostiquer seul la 10 001ème maison.

7. Apprentissage non supervisé

Dans l'apprentissage non supervisé, les données n'ont aucune étiquette ou réponse attendue. L'algorithme est livré à lui-même pour découvrir la structure cachée, les similarités ou les regroupements naturels au sein des données.



Exemple : Profilage de la consommation énergétique Nous relevons la consommation électrique de plusieurs bâtiments, sans aucune autre information :


- Bâtiment A : 1 200 kWh
- Bâtiment B : 1 350 kWh
- Bâtiment C : 4 800 kWh
- Bâtiment D : 5 100 kWh

On pose la question au modèle : > **Existe-t-il des groupes naturels dans ces données ?**

L'algorithme va découvrir de lui-même deux profils distincts (les petits consommateurs autour de 1 300 kWh, et les gros consommateurs autour de 5 000 kWh), sans qu'on lui ait jamais défini ces catégories à l'avance.

8. Apprentissage semi-supervisé

L'apprentissage semi-supervisé est un compromis utilisé lorsque les données brutes sont abondantes, mais que leur étiquetage coûte extrêmement cher (en temps ou en expertise). Il exploite une très petite quantité de données annotées pour guider le traitement d'une vaste majorité de données brutes.



Exemple : Analyse environnementale par satellite Les bases de données fournissent des millions d'images aériennes. Cependant, identifier précisément les types de toitures nécessite l'œil méticuleux d'un spécialiste. On annoté manuellement seulement 2 % des images, et l'algorithme se sert de ces quelques repères solides pour déduire la nature des 98 % d'images restantes.

9. Comparaison des trois approches

Approche	Réponse connue ?	Objectif principal	Exemple d'application
Super-visé	Oui	Prédire une cible précise	Diagnostiquer une anomalie sur une maison
Non supervisé	Non	Découvrir une structure cachée	Regrouper des bâtiments par profil énergétique
Semi-supervisé	Partiellement	Exploiter peu d'exemples sur un grand volume de données	Classifier des toitures avec seulement 2 % d'images annotées

10. Applications concrètes

Santé

Problématique concrète	Type d'approche
Déterminer si une tumeur est bénigne ou maligne à partir d'une IRM	Classification
Estimer le temps d'attente prévu aux urgences en fonction de l'affluence	Régression
Identifier des sous-groupes de diabétiques basés sur leur génétique	Clustering
Détecter un pic de fréquence cardiaque suspect sur un moniteur ECG	Anomalie

Finance

Problématique concrète	Type d'approche
Accorder ou refuser automatiquement un dossier de crédit (Scoring)	Classification
Prédire le chiffre d'affaires d'une entreprise pour le trimestre suivant	Régression
Regrouper les épargnants selon leur niveau d'aversion au risque	Clustering
Bloquer un retrait par carte bancaire effectué depuis un pays inhabituel	Anomalie

Marketing

Problématique concrète	Type d'approche
Prédire si un abonné va résilier son contrat ce mois-ci (Churn)	Classification
Estimer le budget total qu'un client dépensera sur l'année	Régression
Créer des personas (ex: "chasseurs de promos" vs "acheteurs premium")	Clustering
Repérer un robot qui génère des milliers de faux clics sur une publicité	Anomalie

Transition écologique

Problématique concrète	Type d'approche
Identifier le type de culture ou la déforestation sur une image satellite	Classification
Estimer la quantité d'électricité que produira un parc éolien demain	Régression
Cartographier les zones urbaines selon leurs similitudes de pollution de l'air	Clustering
Repérer une micro-fuite d'eau invisible sur le réseau de distribution de la ville	Anomalie

11. Carte mentale finale

