



# L'écosystème Data Python : Maîtriser Pandas

Le premier kilomètre du Data Scientist :  
de la donnée brute à la donnée  
exploitable.



```
import pandas as pd
```

# Le mythe de l'Intelligence Artificielle vs la réalité du Data Scientist




Le Mythe

## La Réalité



**Une grande partie** du travail consiste à rendre les données exploitables. Pandas n'est pas la fin, c'est le **moteur de préparation**.


# L'architecture de la Data Python



# La matrice de l'écosystème : Pourquoi Pandas ?

|                   | Objet Central            | Types de données gérés                    | Modèle mental                                 | Cas d'usage                                    |
|-------------------|--------------------------|-------------------------------------------|-----------------------------------------------|------------------------------------------------|
| <b>Python Pur</b> | Listes/<br>Dictionnaires | Hétérogènes<br>(lents)                    | Programmation<br>classique<br>(boucles)       | Automatisation<br>basique                      |
| <b>NumPy</b>      | ndarray                  | Homogènes<br>(nombres)                    | Algèbre linéaire                              | Opérations<br>mathématiques<br>lourdes         |
| <b>Pandas</b>     | DataFrame &<br>Series    | Hétérogènes<br>(texte, dates,<br>nombres) | Tableur / Base<br>de données<br>relationnelle | Nettoyage,<br>exploration et<br>analyse métier |

# L'anatomie d'un DataFrame




```
df = pd.DataFrame(data)
df["age"] # Extrait une Series
```

# Le changement de paradigme : La Vectorisation


## Boucles Python (Python for loops)

```
for i in range(len(df)):  
    df.loc[i, "salary_k"] = df.loc[i, "salary"] / 1000
```



## Vectorisation Pandas (Pandas Vectorization)

```
df["salary_k"] = df["salary"] / 1000
```



**Ne pensez plus en lignes. Appliquez vos opérations à la colonne entière.**

# Le réflexe du Data Scientist : Le premier contact

1

## Étape 1 : La Vision

```
df.head() / df.tail()
```

Détecter immédiatement les anomalies visuelles (séparateurs incorrects, données décalées).

2

## Étape 2 : L'Envergure

```
df.shape
```

Obtenir le tuple (lignes, colonnes). Mesurer la taille du problème.


3

## Étape 3 : Le Diagnostic complet

```
df.info()
```


L'outil radar. Révèle les valeurs non nulles, les types de données, et la mémoire utilisée.

# Les types dictent les actions



**Si une date ou un nombre apparaît comme object lors de l'appel à `df.info()`, Pandas le traite comme du texte. Une conversion sera obligatoire.**

# L'anatomie de la sélection : Cibler la donnée



## 1. Position absolue (iloc)

Paradigme : Coordonnées (comme une liste Python).

```
df.iloc[0:5, 0:3]
```

Lecture : Les 5 premières lignes, les 3 premières colonnes.



## 2. Labels & Noms (loc)

Paradigme : Noms réels de l'index et des colonnes.

```
df.loc[:, ["country",  
           "category"]]
```

Lecture : Toutes les lignes, uniquement ces deux colonnes spécifiques.




## 3. Requêtes SQL-like (query)

Paradigme : Expression logique textuelle.

```
df.query("amount > 100")
```

Lecture : Évalue cette condition de manière lisible et concise.


# Le secret du filtrage : Le masque booléen




Pandas ne 'cherche' pas. Il évalue une condition sur toute la colonne, crée une série de Vrais/Faux, et superpose ce masque géant.

# Combiner les conditions : Logique avancée


**Porte ET (Le strict) : &**  
(Symbole Ampersand, pas 'and')



**Porte OU (Le flexible) : |**  
(Symbole Pipe, pas 'or')




**L'Alternative élégante : isin()**



# Interroger les catégories : L'art du comptage

## 1. L'Inventaire

```
unique()
```



Quelles sont les valeurs possibles ?

## 2. Le Volume


```
unique()
```

3

Combien de catégories distinctes avons-nous ?


## 3. La Distribution

```
value_counts(normalize=True)
```



`value_counts()` est la commande la plus puissante pour comprendre instantanément la structure d'une variable catégorielle.

# Interroger les nombres : Profilage statistique



Si Moyenne (142€) >> Médiane (72€), alerte : présence de valeurs extrêmes (outliers) tirant la moyenne vers le haut.

## Le radar des extrêmes

```
nlargest(10, "amount")  
nsmallest(10)
```

## Le scanner de vide




```
isna().sum()
```

Un NaN ne signifie pas zéro.  
Cela signifie une absence d'information.  
C'est la première cause d'échec des modèles ML.

# Le principe de chaînage : Répondre aux questions métier

## Question métier :

Quel est le montant moyen des commandes françaises ?



```
df[df["country"] == "France"]["amount"].mean()
```

# Synthèse : La checklist "Premier Contact"

| 1. Structure & Dimensions                                                                                                                                                               | 2. Qualité & Types                                                                                                                                                                                                                                                                 | 3. Profilage Rapide                                                                                                                                                                                             |
|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <ul style="list-style-type: none"><li>✓ <code>df.head()</code> &amp; <code>df.tail()</code><br/>(Anomalies visuelles)</li><li>✓ <code>df.shape</code><br/>(Volume de données)</li></ul> | <ul style="list-style-type: none"><li>✓ <code>df.info()</code><br/>(Types de variables et empreinte mémoire)</li><li>✓ <code>df.isna().sum()</code><br/>(Identification des données manquantes)</li><li>✓ <code>df.duplicated().sum()</code><br/>(Recherche de doublons)</li></ul> | <ul style="list-style-type: none"><li>✓ <code>df.describe(include="all")</code><br/>(Aperçu statistique global)</li><li>✓ <code>df["col"].value_counts()</code><br/>(Distribution des variables clés)</li></ul> |

Une fois cette checklist validée, le véritable nettoyage peut commencer.