



Régression Linéaire : De l'Intuition à l'Implémentation

Comprendre, évaluer et déployer des modèles prédictifs continus.



Cartographie des Problèmes d'Apprentissage

Classification



Prédire une classe / catégorie

- Fraude / Normale
- Malade / Non malade
- Spam / Non spam

Régression




Prédire une valeur numérique

- Montant de la fraude
- Durée d'hospitalisation
- Prix, consommation, température


Notre objectif : Prédire le prix d'un logement (valeur numérique cible Y) à partir de sa surface (variable explicative X).

L'Intuition Visuelle des Données




L'objectif d'une régression est de construire une fonction capable de représenter cette relation pour produire des prédictions.

Anatomie d'un Modèle Linéaire



Exemple : $\hat{y} = 3x + 50$ (prédit 200 k€ pour 50 m²).

Mesurer l'Écart avec la Réalité




Le Résidu

Le modèle ne passe pas par tous les points.

Le résidu mesure l'erreur de prédiction pour chaque observation : l'écart entre la réalité et notre droite.

Pourquoi Mettre l'Erreur au Carré ?




Formule :

$$MSE = \frac{1}{n} \sum (y_i - \hat{y}_i)^2$$

- **Éviter l'annulation :**
(+10) + (-10) = 0. Le carré rend toutes les erreurs positives.
- **Pénalité exponentielle :**
Les grosses erreurs sont sur-pénalisées (Une erreur de 2 donne 4 ; une erreur de 10 donne 100).
- **L'Objectif :** Trouver la droite qui minimise la surface totale de ces carrés.

Le Moteur de Recherche : La Descente de Gradient




Comment la machine trouve-t-elle la meilleure droite ?

1. Paramètres initiaux au hasard.
2. La pente (gradient) indique la direction de la descente.
3. Le taux d'apprentissage (learning rate) contrôle la taille du pas.
4. Répétition jusqu'à atteindre le minimum de la fonction de coût $J(a, b)$.

L'Implémentation en Trois Lignes de Code

```
from sklearn.linear_model import LinearRegression
model = LinearRegression()
model.fit(X, y)
predictions = model.predict(X)
```



L'apprentissage mathématique devient une simple abstraction logicielle.

La Matrice d'Évaluation des Performances

MAE (Mean Absolute Error)

$$\frac{1}{n} \sum |y_i - \hat{y}_i|$$

Hautement interprétable : Le modèle se trompe en moyenne de X k€.

MSE (Mean Squared Error)

$$\frac{1}{n} \sum (y_i - \hat{y}_i)^2$$

Parfait pour l'optimisation mathématique (pénalise les grosses erreurs).

RMSE (Root Mean Squared Error)


$$\sqrt{\text{MSE}}$$

Retourne l'erreur dans l'unité d'origine de la cible (ex: k€).

R² (Coefficient de détermination)

Mesure le pourcentage de variabilité expliqué par le modèle (Proche de 1 = excellent).

L'Illusion de la Perfection et la Règle du Train/Test



Un R^2 élevé sur les données d'entraînement ne garantit rien. Évaluer un modèle sur les données qu'il a apprises, c'est comme donner les réponses d'un examen à un étudiant avant de lui faire passer ce même examen. La véritable mesure est la capacité de généralisation sur des données inédites.

Changement d'Échelle : Le Modèle Multivarié

$$\hat{y} = \beta_0 + \beta_1 x_1$$



$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4$$

Surface (m²)


Nombre de
chambres

Distance au
centre (km)

Âge du bâtiment
(années)

Le prix d'un logement dépend d'une architecture complexe de caractéristiques. La régression linéaire multiple intègre toutes ces dimensions simultanément.

Décoder l'Algorithme : Toutes Choses Égales Par Ailleurs




L'interprétation
fondamentale

Si $\beta_{\text{surface}} = 2.8$, cela signifie qu'une augmentation de 1 m² est associée à une augmentation de 2,8 k€ du prix prédit...


...toutes les autres variables étant maintenues constantes.

Cette capacité d'isolation des variables fait de la régression linéaire un outil d'analyse causale puissant, pas seulement une machine à prédictions.

Le Diagnostic de Qualité par les Résidus




Aucune structure évidente. Les erreurs sont aléatoires.



Une structure visible révèle des problèmes : relation non-linéaire, variance instable, ou variables manquantes.

Synthèse du Cycle de Vie d'une Régression



Briefing de Mission : Consommation Énergétique

La Mission

Construire un modèle capable de prédire la consommation énergétique d'un bâtiment.

- ☐ Explorer les données
- ☐ Identifier la cible
- ☐ Construire et évaluer la régression
- ☐ Analyser les résidus

“

L'objectif final n'est pas seulement d'obtenir un modèle qui fonctionne, mais d'être capable d'expliquer pourquoi vous lui faites — ou non — confiance.