

Niveau 1 : ML ou pas ML ?

1. Identifier le type de problème

Pour chaque situation choisissez parmi : - classification ; - régression ; - clustering ; - détection d'anomalies ; - pas nécessairement du Machine Learning.

Situation A

Calculer automatiquement le montant de la taxe carbone d'une entreprise à partir du barème réglementaire officiel en vigueur.

Situation B

Prédire le niveau de concentration en particules fines (PM10) dans l'air pour la journée de demain dans une grande agglomération.

Situation C

Identifier automatiquement à partir d'images satellites si une parcelle forestière a subi une coupe rase illégale.

Situation D

Regrouper les communes françaises selon des profils de consommation d'eau potable et de taux de fuite sur leurs réseaux.

Situation E

Détecter qu'un capteur de niveau d'eau placé sur un fleuve renvoie soudainement une valeur physiquement impossible.

Situation F

Rechercher tous les documents administratifs contenant le mot-clé exact "biodiversité marine" dans une base d'archives.

Correction du Niveau 1

Situation	Réponse	Explication
A	Pas nécessairement du ML	Une règle réglementaire connue et exacte suffit.
B	Régression	La sortie attendue (concentration) est une valeur numérique continue.
C	Classification	La sortie est binaire : “coupe rase” / “intacte”.
D	Clustering	Les groupes ne sont pas définis à l’avance, on cherche à découvrir des structures.
E	Détection d’anomalies	On recherche des observations inhabituelles ou aberrantes par rapport au comportement normal du capteur.
F	Pas nécessairement du ML	Une simple recherche textuelle déterministe suffit.

Point important : utiliser du Machine Learning simplement parce qu’il est disponible est une mauvaise pratique. Une règle simple, déterministe et fiable est souvent préférable lorsqu’elle suffit.

12. Une démarche de résolution

Une problématique de Machine Learning peut être abordée en plusieurs étapes.

```
graph TD
  A["Problème métier"] --> B{"Une règle simple suffit ?"}
  B -->|"Oui"| C(["Utiliser une solution déterministe"])
  B -->|"Non"| D{"Dispose-t-on de données ?"}
  D -->|"Non"| E(["Collecter des données ou revoir le problème"])
  D -->|"Oui"| F{"Dispose-t-on d'une cible ?"}
  F -->|"Oui"| G(["Apprentissage supervisé"])
  F -->|"Non"| H(["Apprentissage non supervisé ou détection d'anomalies"])

  classDef decision fill:#ffcc80,stroke:#e65100,stroke-width:2px,color:#000
  classDef resultOui fill:#a5d6a7,stroke:#2e7d32,stroke-width:2px,color:#000
  classDef resultNon fill:#ef9a9a,stroke:#c62828,stroke-width:2px,color:#000

  class B,D,F decision
  class C,G,H resultOui
  class E resultNon
```

Cette démarche est volontairement simplifiée, mais elle permet d'éviter une erreur fréquente :

Commencer par choisir un algorithme avant d'avoir correctement défini le problème.

Niveau 2 : Étude de cas (L'efficacité énergétique)

2. Étude de cas : les bâtiments publics

Le ministère dispose d'une base de données concernant plusieurs milliers de bâtiments publics. Pour chaque bâtiment, on connaît : - sa surface en m^2 ; - son année de construction ; - le nombre d'agents y travaillant ; - sa localisation (département) ; - les températures extérieures moyennes ; - son type de chauffage (gaz, électricité, géothermie...) ; - sa consommation énergétique annuelle réelle.

Question 1

Une direction souhaite : > **Prédire la consommation électrique exacte (en kWh) d'un bâtiment pour le trimestre prochain.** Quel type de problème est-ce ?

Question 2

Une direction souhaite : > **Identifier automatiquement des groupes de bâtiments ayant des profils de déperdition thermique similaires pour cibler les campagnes de rénovation.** Quel type de problème est-ce ?

Question 3

Une direction souhaite : > **Déterminer si un bâtiment est susceptible d'être classé comme "passoire thermique" (étiquette F ou G au DPE).** Quel type de problème est-ce ?

Question 4

La consommation d'un bâtiment suit les variations saisonnières habituelles, mais affiche soudainement une consommation nulle en plein hiver alors que le bâtiment est occupé. Quel type de problème peut-on envisager pour repérer cela automatiquement à l'avenir ?

Correction du Niveau 2

Question 1

Régression, car la consommation à prédire (en kWh) est une valeur numérique continue.

Question 2

Clustering, car les “profils de déperdition” ne sont pas connus à l’avance, l’algorithme doit regrouper les bâtiments qui se ressemblent.

Question 3

Classification, car le résultat attendu est une catégorie (Passoire thermique : Oui / Non).

Question 4

Détection d’anomalies, car on cherche à repérer un comportement qui s’écarte drastiquement du fonctionnement habituel normal, potentiellement dû à une panne de compteur.

14. Une première utilisation de scikit-learn

Dans la suite de la formation, nous utiliserons `scikit-learn`.

Une bonne pratique essentielle est de séparer les données destinées à l’apprentissage des données destinées à l’évaluation.

```
graph LR
    A["Jeu de données"] --> B["Train"]
    A --> C["Test"]
    B --> D["Apprentissage du modèle"]
    D --> E["Évaluation"]
    C --> E

    classDef input fill:#e3f2fd,stroke:#1565c0,stroke-width:2px,color:#000
    classDef decision fill:#ffcc80,stroke:#e65100,stroke-width:2px,color:#000
    classDef resultOui fill:#a5d6a7,stroke:#2e7d32,stroke-width:2px,color:#000

    class A input
    class B,C decision
    class D,E resultOui
```

```
class D decision
class E resultOui
```

Pourquoi ?

Si nous évaluons le modèle sur les données qu'il a utilisées pour apprendre, nous risquons d'obtenir une vision trop optimiste de ses performances.

L'objectif est de répondre à la question :

Le modèle fonctionne-t-il sur des données qu'il n'a jamais vues ?

15. Le Data Leakage

Le **Data Leakage**, ou fuite de données, apparaît lorsqu'une information qui ne devrait pas être disponible au moment de la prédiction se retrouve indirectement utilisée par le modèle.

Exemple :

Nous voulons prédire si une maison sera déclarée cher.

Mais nous construisons une variable à partir de la prix annuelle complète, alors que cette prix contient justement l'information permettant de déterminer si la maison est cher.

Le modèle dispose alors d'une information qu'il ne devrait pas connaître.

Une règle fondamentale

Tout ce qui est appris à partir des données doit être appris uniquement sur le jeu d'entraînement.

Cette règle concerne notamment :

- l'imputation des valeurs manquantes ;
- la normalisation ;
- la standardisation ;
- l'encodage ;
- la sélection de variables ;
- la réduction de dimension.

Dans `scikit-learn`, nous utiliserons donc systématiquement les `Pipeline` et `ColumnTransformer` lorsque cela est pertinent.

16. Exemple de Pipeline

Voici un exemple à exécuter pas à pas pour voir les grandes étapes d'un apprentissage machine.

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import OneHotEncoder, StandardScaler
from sklearn.linear_model import LogisticRegression

# 1. GÉNÉRATION DE DONNÉES FICTIVES (Pour les besoins du TP)
np.random.seed(42)
n_samples = 200

# Création d'un jeu de données simulant des prélèvements d'eau
data = pd.DataFrame({
    'ph': np.random.normal(7.2, 0.8, n_samples),
    'temperature_celsius': np.random.normal(15, 5, n_samples),
    'region': np.random.choice(['Bretagne', 'Occitanie', 'Grand_Est'], n_samples),
    'statut': np.random.choice(['Conforme', 'Polluée'], n_samples, p=[0.7, 0.3]) # 70% conforme
})
```

```
print("--- 1. APERÇU DES DONNÉES BRUTES ---")
print(data.head(), "\n")
```

```
--- 1. APERÇU DES DONNÉES BRUTES ---
   ph  temperature_celsius  region  statut
0  7.597371             16.788937  Grand_Est  Conforme
1  7.089389             17.803923  Grand_Est  Conforme
2  7.718151             20.415256  Bretagne  Polluée
3  8.418424             20.269010  Bretagne  Conforme
4  7.012677              8.111653  Grand_Est  Conforme
```

```
# 2. SÉPARATION DES DONNÉES (Train / Test)
X = data[['ph', 'temperature_celsius', 'region']] # Features (Variables explicatives)
y = data['statut']                               # Target (Cible)
```

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
print("--- 2. SÉPARATION DES DONNÉES ---")
print(f"Données d'entraînement : {X_train.shape[0]} prélèvements")
print(f"Données de test (inconnues du modèle) : {X_test.shape[0]} prélèvements\n")
```

--- 2. SÉPARATION DES DONNÉES ---

Données d'entraînement : 160 prélèvements

Données de test (inconnues du modèle) : 40 prélèvements

```
# 3. CRÉATION DU PIPELINE (Préparation + Modèle)
preprocessor = ColumnTransformer(
    transformers=[
        ('num', StandardScaler(), ['ph', 'temperature_celsius']), # Mise à l'échelle des nombres
        ('cat', OneHotEncoder(handle_unknown='ignore'), ['region']) # Encodage du texte
    ]
)

pipeline = Pipeline(steps=[
    ('preprocessor', preprocessor),
    ('classifier', LogisticRegression()) # Algorithme de classification
])
```

```
# 4. APPRENTISSAGE (Entraînement sur X_train)
pipeline.fit(X_train, y_train)
print("--- 3. APPRENTISSAGE ---")
print("Le modèle a terminé son apprentissage sur les données d'entraînement.\n")
```

--- 3. APPRENTISSAGE ---

Le modèle a terminé son apprentissage sur les données d'entraînement.

```
# 5. PRÉDICTION SUR DE NOUVELLES DONNÉES (Le jeu de test)
predictions = pipeline.predict(X_test)

# Affichage des 5 premières prédictions face à la réalité
resultats_comparatifs = pd.DataFrame({
    'Valeur Réelle (y_test)': y_test.head(),
    'Prédiction du modèle': predictions[:5]
})
```

```
print("--- 4. PRÉDICTION SUR LE JEU DE TEST (Extraits) ---")
print(resultats_comparatifs)
```

```
--- 4. PRÉDICTION SUR LE JEU DE TEST (Extraits) ---
    Valeur Réelle (y_test) Prédiction du modèle
95                Conforme          Conforme
15                Conforme          Conforme
30                Conforme          Conforme
158               Polluée           Conforme
128               Polluée           Conforme
```

L'intérêt est de regrouper dans un même objet :

```
préparation des données
      +
transformation
      +
modèle
```

Cela limite notamment les risques de réaliser par erreur une transformation sur l'ensemble des données avant la séparation train/test.

Niveau 3 : Challenge

17. Challenge : faut-il utiliser du Machine Learning ?

Vous êtes consultant en Data Science pour une entreprise.

Pour chaque situation, vous devez répondre à quatre questions :

1. Le Machine Learning est-il pertinent ?
2. Quel type d'apprentissage ?
3. Quel type de problème ?
4. Quelles données seraient nécessaires ?

Cas 1 — Pr vision de trafic

Une organisation souhaite pr voir le nombre de v hicules circulant sur une portion d'autoroute dans les 30 prochaines minutes.

R fl chissez notamment aux variables suivantes :

```
heure  
jour de la semaine  
vacances scolaires  
m t o  
historique du trafic  
accidents  
travaux  
...
```

Cas 2 — Surveillance de transactions

Des milliers de transactions industriels transmettent des mesures toutes les cinq minutes. Le syst me doit signaler automatiquement les comportements inhabituels.

Questions :

- Avons-nous forc ment besoin d'une cible ?
- Peut-on apprendre ce qu'est un comportement normal ?
- Quel probl me cela  voque-t-il ?

Cas 3 — Classification de documents

Une administration re oit automatiquement des milliers de documents. Elle souhaite les classer dans diff rentes cat gories.

Exemples :

```
urbanisme  
transport  
prix  
biodiversit   
eau  
d chets  
...
```

Questions :

- Comment obtenir la cible ?
- S'agit-il d'une classification ?
- Que se passe-t-il si seulement 5 % des documents sont annotés ?

Cas 4 — Calcul réglementaire

Une application doit déterminer le montant d'une taxe à partir de paramètres définis précisément par la réglementation.

Question :

Pourquoi serait-il probablement inutile d'utiliser du Machine Learning ?

Correction du challenge

Cas 1 — Prédiction de trafic

Machine Learning : oui, potentiellement.

Type :

Régression, car la sortie est un nombre.

On dispose généralement de nombreuses données historiques permettant de construire un problème supervisé.

Cas 2 — Surveillance de transactions

Machine Learning : potentiellement oui.

Une approche possible est la **détection d'anomalies**.

On peut notamment apprendre le comportement habituel des transactions puis détecter les observations qui s'en éloignent.

Une approche supervisée est également possible si l'on dispose d'un historique suffisamment riche d'incidents correctement étiquetés.

Cas 3 — Classification de documents

Machine Learning : oui.

Il s'agit d'un problème de **classification supervisée** si les documents sont déjà étiquetés.

Si seulement une petite proportion des documents est annotée, on peut envisager :

- davantage d'annotation ;
- de l'apprentissage semi-supervisé ;
- d'autres techniques permettant d'exploiter les documents non annotés.

Cas 4 — Calcul réglementaire

Machine Learning : généralement non.

Si la réglementation définit précisément le calcul, une fonction déterministe est préférable.

```
Entrées  
  ↓  
Règle réglementaire  
  ↓  
Résultat
```

Il n'est pas pertinent de demander à un modèle statistique d'apprendre une règle que nous connaissons déjà exactement.

18. Les erreurs à éviter

Erreur 1 — « Il y a beaucoup de données, donc il faut du ML »

Faux.

Une grande quantité de données ne signifie pas automatiquement qu'un modèle de Machine Learning est nécessaire.

Erreur 2 — « Le Machine Learning trouve toujours la meilleure solution »

Faux.

Un modèle peut :

- apprendre des biais ;
- être trop complexe ;
- mal généraliser ;
- être difficile à expliquer ;
- nécessiter beaucoup de maintenance.

Erreur 3 — Commencer par l'algorithme

Mauvaise démarche :

```
J'utilise Random Forest.  
Quel problème puis-je lui donner ?
```

Bonne démarche :

```
Problème métier  
    ↓  
Données disponibles  
    ↓  
Type de problème  
    ↓  
Critère de succès  
    ↓  
Méthode appropriée  
    ↓  
Algorithme
```

Erreur 4 — Confondre corrélation et causalité

Un modèle peut découvrir une relation statistique sans que cette relation soit causale.

Exemple simplifié :

Les maisons consommant beaucoup d'énergie sont souvent occupées par davantage de personnes.

Cela ne signifie pas nécessairement que le nombre d'agents est **la cause principale** de toutes les différences de prix.

19. Synthèse

À ce stade, vous devez retenir cinq idées.

1. Le Machine Learning apprend à partir de données

Données → apprentissage → modèle → prédiction

2. Il existe plusieurs familles d'apprentissage

Supervisé
Non supervisé
Semi-supervisé

3. Les problèmes supervisés les plus courants sont

Classification → catégorie
Régression → nombre

4. Le non supervisé permet notamment

Clustering → groupes
Détection d'anomalies → comportements inhabituels

5. Le ML n'est pas toujours nécessaire

Toujours commencer par le problème métier avant de choisir une technologie.

20. Carte mentale finale

```

graph TD
    ML["Machine Learning"]

    ML --> SUP["Supervisé"]
    ML --> UNSUP["Non supervisé"]
    ML --> SEMI["Semi-supervisé"]

    SUP --> CLASS["Classification"]
    SUP --> REG["Régression"]

    UNSUP --> CLUST["Clustering"]
    UNSUP --> ANOM["Détection d'anomalies"]

    CLASS --> C1(["Catégorie"])
    REG --> R1(["Nombre"])
    CLUST --> C2(["Groupes"])
    ANOM --> C3(["Observations inhabituelles"])

    classDef decision fill:#ffcc80,stroke:#e65100,stroke-width:2px,color:#000
    classDef resultOui fill:#a5d6a7,stroke:#2e7d32,stroke-width:2px,color:#000
    classDef resultNon fill:#ef9a9a,stroke:#c62828,stroke-width:2px,color:#000

    class ML,SUP,UNSUP,SEMI,CLASS,REG,CLUST,ANOM decision
    class C1,R1,C2,C3 resultOui

```

21. Pour aller plus loin

La prochaine étape consiste à passer de la question :

« Quel type de problème avons-nous ? »

à :

« Comment un algorithme apprend-il réellement à partir des données ? »

Nous allons alors introduire progressivement :

- les jeux de données ;
- X et y ;
- l'entraînement et la prédiction ;
- la fonction de coût ;

- l'évaluation ;
- le surapprentissage (*overfitting*) ;
- la généralisation ;
- puis les premiers algorithmes de Machine Learning.

À retenir

Le Machine Learning n'est pas une technologie que l'on applique indistinctement à tous les problèmes.

La première compétence d'un Data Scientist est de transformer une **problématique métier** en un **problème d'apprentissage correctement défini**.