

Module 0 — L'écosystème Data Python

Manipulation des données avec Pandas — Devenir Data Scientist

18. Mini-TP — Prise en main

Nous allons utiliser le DataFrame suivant :

```
import pandas as pd
```

```
data = {
    "name": [
        "Alice", "Bob", "Charlie",
        "David", "Emma", "Frank"
    ],
    "age": [32, 41, 27, 35, 29, 52],
    "city": [
        "Paris", "Lyon", "Paris",
        "Marseille", "Lyon", "Paris"
    ],
    "salary": [
        42000, 58000, 39000,
        51000, 45000, 72000
    ]
}

df = pd.DataFrame(data)

df
```

	name	age	city	salary
0	Alice	32	Paris	42000
1	Bob	41	Lyon	58000
2	Charlie	27	Paris	39000
3	David	35	Marseille	51000
4	Emma	29	Lyon	45000
5	Frank	52	Paris	72000

Questions

1. Combien y a-t-il de lignes et de colonnes ?

```
df.shape
```

(6, 4)

2. Quels sont les noms des colonnes ?

```
df.columns
```

```
Index(['name', 'age', 'city', 'salary'], dtype='object')
```

3. Quels sont les types des colonnes ?

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 6 entries, 0 to 5
Data columns (total 4 columns):
#   Column  Non-Null Count  Dtype
---  -
0   name    6 non-null       object
1   age     6 non-null       int64
2   city    6 non-null       object
3   salary  6 non-null       int64
dtypes: int64(2), object(2)
memory usage: 324.0+ bytes
```

```
df.dtypes
```

```
name      object
age       int64
city      object
salary    int64
dtype: object
```

4. Affichez uniquement les colonnes `name` et `salary`.

```
df[["name", "salary"]]
```

	name	salary
0	Alice	42000
1	Bob	58000
2	Charlie	39000
3	David	51000
4	Emma	45000
5	Frank	72000

5. Quel est le salaire moyen ?

```
df["salary"].mean()
```

```
np.float64(51166.666666666664)
```

```
df.salary.mean()
```

```
np.float64(51166.666666666664)
```

6. Quels sont les employés de plus de 30 ans ?

```
df[df["age"] > 30]
```

	name	age	city	salary	salary_k
0	Alice	32	Paris	42000	42.0
1	Bob	41	Lyon	58000	58.0
3	David	35	Marseille	51000	51.0
5	Frank	52	Paris	72000	72.0

7. Créez une colonne `salary_k` contenant le salaire en milliers d'euros.

```
df["salary_test"] = df.salary // 1000
df
```

	name	age	city	salary	salary_k	salary_test
0	Alice	32	Paris	42000	42.0	42
1	Bob	41	Lyon	58000	58.0	58
2	Charlie	27	Paris	39000	39.0	39
3	David	35	Marseille	51000	51.0	51
4	Emma	29	Lyon	45000	45.0	45
5	Frank	52	Paris	72000	72.0	72

```
df.dtypes
```

```
name          object
age           int64
city          object
salary        int64
salary_k      float64
salary_test   int64
dtype: object
```

19. Challenge

Sans utiliser de boucle `for` :

Trouvez les personnes de plus de 30 ans qui gagnent plus de 50 000 €.

Indice :

```
df[
    (condition_1)
    & (condition_2)
]
```

```
df[(df["age"] > 30) & (df["salary"] > 50000)]
```

	name	age	city	salary	salary_k	salary_test
1	Bob	41	Lyon	58000	58.0	58
3	David	35	Marseille	51000	51.0	51
5	Frank	52	Paris	72000	72.0	72

20. À retenir

NumPy

Calcul numérique et tableaux multidimensionnels

```
np.array(...)
```

Pandas Series

Une colonne de données

```
pd.Series(...)
```

Pandas DataFrame

Une table de données

```
pd.DataFrame(...)
```

Les opérations fondamentales

```
Explorer
↓
Sélectionner
↓
Filtrer
↓
Transformer
↓
Agréger
↓
Combiner
↓
Analyser
```

21. La question importante

Un Data Scientist ne passe pas directement de :

```
Données
↓
Modèle ML
```

Il passe généralement par :

```
Données brutes
↓
Comprendre
↓
Nettoyer
↓
Transformer
↓
Analyser
↓
Feature Engineering
↓
Dataset ML
↓
Modèle
```

Une grande partie du travail de Data Science consiste à rendre les données exploitables.

Et Pandas est l'un des outils principaux pour effectuer ce travail.

Suite du cours

Dans le prochain module, nous allons apprendre à **explorer et sélectionner efficacement les données**.

Nous verrons notamment :

```
head()
tail()
shape
columns
dtypes
info()
describe()

+

[]
[[]]
iloc
loc

+

conditions
isin()
between()
query()
```

L'objectif sera de pouvoir prendre un dataset inconnu et répondre rapidement à la question :

“Qu’est-ce qu’il y a réellement dans ces données ?”