

QCM : Machine Learning, Algorithmes et Pandas

Ce questionnaire de 40 questions évalue vos connaissances sur la préparation des données, les concepts fondamentaux du Machine Learning et les différents algorithmes étudiés.

Partie 1 : Introduction et Manipulation avec Pandas

1. **Qu'est-ce que le Machine Learning ?**
 - A. Une méthode permettant à un algorithme d'apprendre des modèles à partir de données.
 - B. Un mixeur haute technologie pour la cuisine.
 - C. Une série de règles conditionnelles écrites manuellement par un développeur.
2. **Quelle est la différence entre l'apprentissage supervisé et non supervisé ?**
 - A. L'apprentissage supervisé a un chef de projet, le non supervisé est en roue libre.
 - B. L'apprentissage supervisé utilise des données étiquetées (avec la réponse), le non supervisé n'en a pas.
 - C. L'apprentissage supervisé est toujours beaucoup plus rapide.
3. **À quoi sert le jeu d'entraînement (train set) ?**
 - A. À muscler le processeur de l'ordinateur.
 - B. À évaluer la performance finale du modèle.
 - C. À fournir les exemples sur lesquels l'algorithme va apprendre.
4. **Qu'est-ce que le surapprentissage (overfitting) ?**
 - A. Le fait que l'ordinateur chauffe trop pendant les calculs.
 - B. Quand le modèle apprend par cœur les données d'entraînement et échoue sur de nouvelles données.
 - C. Quand le modèle est beaucoup trop simple pour comprendre la logique des données.
5. **Dans un DataFrame Pandas, que représente généralement une ligne ?**
 - A. Une observation ou un individu unique dans le jeu de données.
 - B. Une caractéristique ou une variable.
 - C. Une ligne de code Python très compliquée.
6. **Comment gère-t-on le plus souvent les valeurs manquantes (NaN) avec Pandas ?**
 - A. On met du blanc correcteur sur l'écran pour ne plus les voir.
 - B. On supprime les lignes concernées ou on remplace la valeur manquante (par exemple par la moyenne).
 - C. On laisse l'algorithme deviner au hasard.
7. **Que fait la méthode head() lorsqu'elle est appliquée à un DataFrame Pandas ?**
 - A. Elle affiche un aperçu des premières lignes du tableau.
 - B. Elle met un chapeau virtuel sur la première colonne du fichier.
 - C. Elle supprime toutes les données pour ne garder que le titre.
8. **Lequel de ces problèmes est un cas de classification ?**
 - A. Prédire le prix d'une maison en euros.
 - B. Prédire si un email reçu est un "Spam" ou "Non Spam".

- C. Ranger les câbles de l'ordinateur par ordre de taille.
- 9. **Lequel de ces problèmes est un cas de régression ?**
 - A. Prédire la température de demain en degrés.
 - B. Identifier si une image contient un chat ou un chien.
 - C. Prédire son avenir amoureux en lisant dans les cartes.
- 10. **À quoi sert la méthode "groupby" dans Pandas ?**
 - A. À créer un groupe WhatsApp avec les membres de l'équipe de données.
 - B. À mélanger aléatoirement toutes les lignes du tableau.
 - C. À regrouper les données selon une catégorie pour calculer des statistiques agrégées.

Partie 2 : Distances, kNN et K-Means

- 11. **Sur quoi l'algorithme kNN (k-Nearest Neighbors) base-t-il sa prédiction ?**
 - A. Les prévisions météo du jour.
 - B. La classe majoritaire parmi ses 'k' voisins les plus proches.
 - C. Une équation mathématique créant une ligne droite.
- 12. **Dans l'algorithme kNN, que représente le paramètre "k" ?**
 - A. Le nombre de voisins à prendre en compte pour prendre une décision.
 - B. Le poids du fichier de données en kilo-octets.
 - C. La lettre initiale de son créateur.
- 13. **Que se passe-t-il dans kNN si l'on choisit k=1 ?**
 - A. Le modèle prend simplement la classe de l'unique point d'entraînement le plus proche.
 - B. L'algorithme plante irrémédiablement.
 - C. Il demande l'avis du public.
- 14. **Lequel de ces algorithmes est un modèle d'apprentissage NON supervisé ?**
 - A. La régression linéaire.
 - B. K-Means (les K-Moyennes).
 - C. La règle de trois.
- 15. **Quel est l'objectif principal de l'algorithme K-Means ?**
 - A. Prédire le prix d'un article.
 - B. Trouver le centre géométrique de la Terre.
 - C. Regrouper les données en 'K' clusters (groupes) homogènes en fonction de leurs similarités.
- 16. **Que représente un "centroïde" dans K-Means ?**
 - A. Un droïde astromech dans Star Wars.
 - B. Le point central virtuel (la moyenne) d'un cluster.
 - C. Le point le plus éloigné du jeu de données.
- 17. **Comment l'algorithme K-Means assigne-t-il un point à un cluster ?**
 - A. En l'assignant au centroïde dont la distance est la plus courte.
 - B. En tirant à pile ou face.
 - C. En demandant à l'utilisateur de cliquer dessus.
- 18. **Est-il important de mettre les données à la même échelle (scaling) avant d'utiliser kNN ou K-Means ?**
 - A. Seulement les jours de pleine lune.
 - B. Non, cela abîme les données d'origine.

- C. Oui, car ces algorithmes basent leurs décisions sur des calculs de distances.

Partie 3 : Arbres de Décision et Forêts Aléatoires (Random Forests)

- 19. Comment fonctionne le principe de base d'un arbre de décision ?**
 - A. Il fait pousser des branches virtuelles en 3D sur l'écran.
 - B. Il pose une série de questions (règles si/alors) pour séparer progressivement les données.
 - C. Il trace une droite qui coupe l'écran en deux.
- 20. Qu'est-ce qu'une "feuille" dans le contexte d'un arbre de décision ?**
 - A. Un élément décoratif pour rendre l'algorithme plus vert.
 - B. Le point de départ de l'algorithme.
 - C. Le nœud final qui donne la décision ou prédiction.
- 21. Quel est le principal risque d'un arbre de décision très profond (beaucoup de conditions) ?**
 - A. Le sous-apprentissage.
 - B. Qu'il perde ses feuilles en automne.
 - C. Le surapprentissage (overfitting) : il apprend par cœur les données d'entraînement.
- 22. Qu'est-ce qu'une "Random Forest" (Forêt Aléatoire) ?**
 - A. Un ensemble (une forêt) de plusieurs arbres de décision qui votent ensemble.
 - B. Un fond d'écran Windows populaire dans les années 2000.
 - C. Un seul arbre géant et très complexe.
- 23. Pourquoi utiliser une Random Forest plutôt qu'un seul arbre de décision ?**
 - A. Pour économiser de l'électricité.
 - B. Parce que cela sonne plus écologique lors des réunions.
 - C. Pour obtenir un modèle plus robuste et réduire les risques de surapprentissage.
- 24. Comment la Random Forest fait-elle sa prédiction finale en classification ?**
 - A. Elle choisit l'arbre le plus grand du modèle.
 - B. Par un vote majoritaire de tous les arbres qui la composent.
 - C. Elle demande conseil à un garde forestier.
- 25. Que signifie le terme "Random" (aléatoire) dans Random Forest ?**
 - A. Les prédictions finales sont tirées au sort.
 - B. Le programme s'exécute à des heures aléatoires de la journée.
 - C. Chaque arbre est entraîné sur un échantillon aléatoire de données et avec un sous-ensemble aléatoire de caractéristiques.
- 26. Pour quels types de tâches peut-on utiliser une Random Forest ?**
 - A. Uniquement pour la classification d'images d'arbres.
 - B. Aussi bien pour des tâches de classification que de régression.
 - C. Uniquement si les données sont au format texte.

Partie 4 : Réseaux Neuronaux et Évaluation des Modèles

- 27. De quoi s'inspirent originellement les réseaux neuronaux artificiels ?**

- A. Du réseau routier national.
- B. Du fonctionnement interconnecté des neurones du cerveau humain.
- C. Des toiles d'araignées dans la salle des serveurs.

28. Qu'est-ce qu'un "perceptron" ?

- A. Un super-héros issu de l'univers Marvel.
- B. Un nouvel outil de nettoyage de base de données.
- C. L'unité de base, ou neurone artificiel, constituant un réseau.

29. À quoi servent les "couches cachées" (hidden layers) dans un réseau de neurones ?

- A. À cacher les données sensibles pour respecter le RGPD.
- B. À extraire des motifs complexes et non linéaires dans les données.
- C. À jouer à cache-cache avec le processeur.

30. Qu'est-ce qu'une "fonction d'activation" dans un réseau de neurones ?

- A. Une fonction mathématique qui détermine si le neurone doit transmettre son signal.
- B. Un bouton rouge sur le clavier pour lancer l'entraînement.
- C. Un script qui active l'antivirus de l'ordinateur.

31. Qu'est-ce que le "Deep Learning" (Apprentissage profond) ?

- A. Un modèle qui explore les abysses des océans.
- B. Un algorithme qui réfléchit très profondément avant de répondre.
- C. L'utilisation de réseaux de neurones possédant un grand nombre de couches cachées.

32. Quel algorithme est classiquement utilisé pour ajuster les poids d'un réseau de neurones et réduire son erreur ?

- A. Le retour vers le futur.
- B. Le grand nettoyage de printemps.
- C. La rétropropagation du gradient (Backpropagation).

33. Pour quels domaines les réseaux neuronaux profonds excellent-ils particulièrement ?

- A. Trier un petit fichier Excel de 10 lignes.
- B. La préparation des commandes dans un fast-food.
- C. La reconnaissance d'images, le traitement du langage naturel et l'audio.

34. Qu'est-ce qu'une matrice de confusion ?

- A. Un tableau qui permet d'évaluer les performances d'un modèle en croisant prédictions et réalités.
- B. Un labyrinthe mathématique dont personne ne sort.
- C. L'expression d'un développeur face à un bug.

35. Dans l'équation de régression $Y = aX + b$, que représente "a" ?

- A. La longueur du fichier.
- B. Le poids ou coefficient donné à la variable X.
- C. Le mot de passe de l'ordinateur.

36. Qu'est-ce qu'un Faux Positif (False Positive) ?

- A. Le modèle a prédit que l'événement allait arriver, mais il ne s'est rien passé.
- B. Un sourire hypocrite sur une photo.
- C. Le modèle a correctement prédit que l'événement ne se produirait pas.

37. Pourquoi la métrique de l'accuracy (précision globale) peut-elle être mauvaise ?

- A. Elle change selon la météo.
- B. Si les classes sont très déséquilibrées (ex: 99% d'exemples normaux et 1%

d'anomalies).

- C. Parce qu'elle est calculée par un dé à six faces.

38. Pourquoi est-il indispensable de faire une analyse exploratoire (EDA) avant de modéliser ?

- A. Pour comprendre la distribution des données, repérer les erreurs et choisir les bonnes variables.
- B. Pour faire du tourisme virtuel dans les serveurs de l'entreprise.
- C. Pour inventer des données qui donneront un meilleur résultat final.

39. Si votre algorithme est anormalement lent à s'entraîner, quelle peut être la raison ?

- A. Les données sont écrites avec une police de caractères trop petite.
- B. Il a besoin qu'on lui serve un café serré.
- C. Le jeu de données est très volumineux ou le modèle est trop complexe.

40. En Data Science, que signifie "Garbage In, Garbage Out" ?

- A. Que les IA font le tri sélectif automatiquement.
- B. Que des données de mauvaise qualité produiront forcément un mauvais modèle prédictif.
- C. Qu'il faut vider la corbeille de l'ordinateur avant de lancer Python.